

一、预测未来供货量

1.1 基于神经网络的供货能力预测

为了优化订购方案，首先需要确定可能的供应量，因此对筛选后的供货商的供应量进行预测，再据此制定相应的订货方案。订货商的供应量受多种不可控因素影响，若仅根据时间变量构建时间序列预测模型，难以准确拟合供应量曲线，预测效果差。若将其做主要影响因素的回归分析，由于影响因素众多且相互耦合，无法综合分析，与此同时，预测过程中也有预测函数难以构建的问题^[1]。

对于复杂的长时间序列预测的问题，相比于传统时间序列预测手段，深度学习方法有着更好的拟合与预测能力。深度学习模型是一种拥有多个非线性映射层级的深度神经网络模型，能够对输入信号逐层抽象并提取特征，挖掘出更深层次的潜在规律^[2]。其中，LSTM 模型弥补了循环神经网络的梯度消失和梯度爆炸、长期记忆能力不足等问题，使得循环神经网络能够真正有效地利用长距离的时序信息^[3]。

因此，本文使用 LSTM 分别对选中的 44 家公司的供货量进行预测。在过去五年的交易数据中，以前四年训练神经网络，取第五年为测试集。

LSTM 是由各个节点组成的。在每个节点中，总体上有 3 个阶段：

(1) 忘记阶段——对上一个节点的输入进行选择性的忘记

$$Z^f = \sigma \left(\begin{matrix} \omega^f & y(t) \\ & h^{t-1} \end{matrix} \right). \quad (1)$$

(2) 记忆阶段——选择有效的输入值

$$Z^i = \sigma \left(\begin{matrix} \omega^i & y(t) \\ & h^{t-1} \end{matrix} \right). \quad (2)$$

(3) 选择阶段——选择输出并放缩

$$Z^j = \sigma \left(\begin{matrix} \omega^o & y(t) \\ & h^{t-1} \end{matrix} \right) = \tanh \left(\begin{matrix} \omega & y(t) \\ & h^{t-1} \end{matrix} \right). \quad (3)$$

其中， Ω 、 ω^f 、 ω^o 、 ω^i 为权重矩阵，激活函数 σ 会输出一个 0 到 1 之间的数值，来作为一种门控状态。

具体来说，LSTM 的节点可由图 2 表示




图 2 LSTM 网络结构图

Fig. 2 LSTM network structure diagram

图中,

$$\begin{aligned} c^\omega &= Z^f \odot c^{\omega-1} + Z^i \odot Z, \\ h^\omega &= Z^j, \\ y^\omega &= \sigma(\omega^{th^\omega}); \end{aligned} \quad (4)$$

而第 ω 个节点输出的, 即为预测值 $\hat{y}_{\omega,n}$, 其能反映第 n 家供货商在第 ω 周的供货能力。

通过分析往年交易数据, 供应商总是根据企业订货量来供应原材料。由于没有考虑提高订购量对供应量的影响, 仅根据往年交易数据进行预测, 模型对供应商实际供应的预测值会偏小。通过对预测结果的检验, 预测中筛选得到的供应商的总供应量确实小于预期。

1.2 供应量修正

为了提高预测的准确性, 本文为模型添加了反映订货量影响的修正。数据显示, 一定范围内, 供应商的供应量会随订货量的增加而增多。而当订货量超出其的供应能力后, 供应商的供货量限于生产条件达到其最大值, 即最大供应量。

进而定义该家供货商的修正比 A_n :

$$A_n = \frac{B_n - c_n}{c_n} \quad (5)$$

在第 n 家供应商的历史数据中, 求符合上述特征的该周供货量的平均值, 记为 B_n , 而 c_n 为其他周的供货量的平均值。

修正后第 n 家供货商在第 ω 周的实际供货能力 $\hat{y}'_{\omega,n} = \text{预测值} \times A_n$ 。

1.3 预测模型检验

本文基于企业前四年的供应数据, 建立如上原材料供应量预测模型, 并将模型预测结果与真实数据比较以检验模型预测准确性, 如下图所示:




图2 拟合验证图

Fig.2 Comparison

拟合效果较好，故采取该预测模型以预测供应商供货量。

参考文献

- [1] 李鹏, 何帅, 韩鹏飞, 等. 基于长短期记忆的实时电价条件下智能电网短期负荷预测[J]. 电网技术, 2018, 42(12): 4045-4052.
- [2] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [3] 王鑫, 吴际, 刘超, 等. 基于 LSTM 循环神经网络的故障时间序列预测[J]., 2018.