

一、预测未来供货量

1.1 基于神经网络的供货能力预测

为了优化订购方案，首先需要确定可能的供应量，因此对筛选后的供货商的供应量进行预测，再据此制定相应的订货方案。供应商接受订单后，会在自身供货能力范围内，调整供货量以满足订单需要。当订货量过大时，供应商会仅能提供其最大供应量，因此往年供应数据可以反映出供应商的供货能力上限，本文依据供应商历史供应情况来预测其未来供应情况。

订货商的供应量受多种不可控因素影响，若仅根据时间变量构建时间序列预测模型，难以准确拟合供应量曲线，预测效果差。若将其做主要影响因素的回归分析，由于影响因素众多且相互耦合，无法综合分析，与此同时，预测过程中也有预测函数难以构建的问题^[1]。

对于复杂的长时间序列预测的问题，相比于传统时间序列预测手段，深度学习方法有着更好的拟合与预测能力。深度学习模型是一种拥有多个非线性映射层级的深度神经网络模型，能够对输入信号逐层抽象并提取特征，挖掘出更深层次的潜在规律^[2]。其中，LSTM 模型弥补了循环神经网络的梯度消失和梯度爆炸、长期记忆能力不足等问题，使得循环神经网络能够真正有效地利用长距离的时序信息^[3]。

因此，本文使用 LSTM 分别对选中的 44 家公司的供货量进行预测。本文在过去五年的交易数据中，以前四年训练神经网络，取第五年为测试集。

LSTM 是由一系列节点（又称 LSTM 单元）组成的。如图??? 所示，LSTM 单元内部主要有三个阶段。在第 t 个节点中：

(1) 忘记阶段——对上一个节点的输入进行选择性的忘记，即遗忘门

$$f^t = \sigma \left(\omega^f \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (1)$$

该阶段通过 Sigmoid 函数，计算得到的 f^t 是一个向量，且每个分量均属于 $[0, 1]$ 。一般分量的值会极其接近 0 或 1，为后续选择 c^{t-1} 中用于计算 c^t 的特征做准备。

(2) 记忆阶段——选择有效的输入值，即输入门

$$i^t = \sigma \left(\omega^i \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (2)$$

该阶段工作原理与忘记阶段类似，将用于对输入的 x^t 进行选择。

(3) 选择阶段——选择输出并放缩，即输出门

$$o^t = \sigma \left(\omega^o \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (3)$$

本阶段得到的 o^t 会放缩 c^t ，进而决定节点的输出

LSTM 的优势是前一节点的状态将随数据一起传入后一节点，但并不向外输出，具体来说也有三个：

(1) 单元状态更新值

$$\tilde{c}^t = \sigma \left(\omega^c \begin{pmatrix} x^t \\ h^{t-1} \end{pmatrix} \right). \quad (4)$$

事实上，单元状态更新值与遗忘门、输入门和输出门的作用类似，而且并不传入后一节点。

(2) 单元状态

$$c^t = f^t c^{t-1} + i^t \tilde{c}^t. \quad (5)$$

(3) 隐藏状态

$$h^t = o^t \tanh(c^t). \quad (6)$$

最终节点的输出 y^t 也是由 h^t 变化而成的，本文使用的是

$$y^t = \sigma(\omega' h^t), \quad (7)$$

在后文中，使用 ψ_{ij} 以表示，即通过预测得到的第 i 周第 j 家供应商的供应量。

本文的 LSTM 是由 PyTorch 实现的，结构如图??? 所示：

Algorithm 1 Long short-term memory for out model.

Input: 从原始数据中获取原始的订购与供应数据; 从原始数据中挑取前一步筛选的 44 家供应商信息;

Output: 第 i 周第 j 家供应商的预测值 ψ_{ij} ;

- 1: 对数据的 A、B、C 分类，做均一化预处理;
 - 2: 将数据按供应商拆分为一维时间序列数据;
 - 3: 将一维时间序列数据先按时间窗口切分为二维数据，以同样的方法，再将每个时间窗口中的数据切分为特征向量;
 - 4: 对升维后的数据做一次正态标准化缩放，保存缩放参数;
 - 5: 将处理后的数据送入 LSTM 网络，训练完毕后，返回神经网络;
 - 6: 每次预测 1 周，将预测的得到的 1 周数据重新送入神经网络，迭代指定此时以得到相应的预测步数;
 - 7: 使用保存的缩放数据，将预测数据复原。
 - 8: **return** ψ_{ij} .
-




图 2 LSTM 网络结构图

Fig. 2 LSTM network structure diagram

通过分析往年交易数据，供应商总是根据企业订货量来供应原材料。由于没有考虑提高订购量对供应量的影响，仅根据往年交易数据进行预测，模型对供应商实际供应的预测值会偏小。通过对预测结果的检验，预测中筛选得到的供应商的总供应量确实小于预期。

1.2 供应量修正

为了提高预测的准确性，本文为模型添加了反映订货量影响的修正。数据显示，一定范围内，供应商的供应量会随订货量的增加而增多。而当订货量超出其的供应能力后，供应商的供货量限于生产条件达到其最大值，即最大供应量。

进而定义该家供货商的修正比 α_j ：

$$\alpha_j = \frac{\beta_j - \gamma_j}{\gamma_j}, \quad (8)$$

在第 j 家供应商的历史数据中，当供货量超过订货量时供货量的平均值记为 B_n ，而 c_n 为当供货量小于订货量时供货量的平均值。

修正后第 j 家供货商在第 i 周的实际供货能力 $\hat{\psi}_{ij} = \alpha_j y_j^i$ 。

1.3 预测模型检验

本文基于企业前四年的供应数据，建立如上原材料供应量预测模型，并将模型预测结果与真实数据比较以检验模型预测准确性，如下图所示：




图2 拟合验证图

Fig.2 Comparison

拟合效果较好，故采取该预测模型以预测供应商供货量。

参考文献

- [1] 李鹏, 何帅, 韩鹏飞, 等. 基于长短期记忆的实时电价条件下智能电网短期负荷预测[J]. 电网技术, 2018, 42(12): 4045-4052.
- [2] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [3] 王鑫, 吴际, 刘超, 等. 基于 LSTM 循环神经网络的故障时间序列预测[J]., 2018.