

生产企业原材料的订购与运输

摘要

近年，随着世界全球化加深，传统的供应关系已经不再适应于当今生产需要，其中原材料供应是企业供应链的主要环节。本文提出了原材料供应数学模型的基础假设，给出企业对供应过程中订购与运输方案的建议。基于 TOPSIS 法，通过 EWM 分析供应商的产业规模、供货能力、违约率、波动情况，建立原材料供应商的综合评价体系，得出对企业生产最重要的 44 家供货商，并根据 LSTM 预测供应商的供货偏差，以此运用线性规划方法制定出未来 24 周订购方案，检验了方案的优化效果。

关键字： TOPSIS 法 熵权法 LSTM 模型 线性规划

原材料是企业重要的经营性资产，是企业维持正常生产经营活动的基础，原材料管理的好坏直接关系到企业的营运资金利用效率，也关系到企业生产经营的持续性^[1]。改良生产企业的原材料管理方案，能提高原材料的周转率，有效降低仓储成本，也有利于保障生产流程的正常运行，在较大程度上加强企业竞争力^[2]。近年来，随着经济的稳步发展，企业在面对新冠疫情冲击的同时，还面临着更大规模、更高强度的竞争，优化原材料管理方案也较以往更具现实意义。

一、问题分析

制造商为了达到每日生产指标，以满足市场需求，需要向供货商（提供企业所需的原材料）提交订单。由于运输、交付等问题，订购的原材料不能直接用于生产，而需先交付物流转运至仓库，以便企业生产时取用。

现实中，供应商在接到订单后，常因为生产能上限和供应优先度等问题调整原材料产量，导致实际按时提供的原料量与生产需要存在出入。而此时制造商已经完成原料采购，不能通过更改之前的订购方案来弥补缺少原料，只能使用已经转移至仓库中的原料进行加工。若原材料库存不足，原材料的缺口会导致生产线停摆，造成严重的经济损失。为了减轻原料供应量波动对生产的影响，生产企业可提前储存一些原料，减轻生产停摆带来的损失。但与此同时，过多的原材料积存会显著增加企业的仓储成本。因此，为了改良生产企业的原材料管理方案，可根据以往交易数据，推测该供应商供应量的波动幅度，以制定出更加灵活的订购方案，削弱仓储成本，为企业带来更大收益。

供应商提供 A、B、C 三种原材料，容易发现，A、B、C 三种类型的原材料在采购单价不相等的同时，生产单位商品的消耗量也是不同的。其中，A 类型和 C 类型原材料生产单位商品的采购费用相等，且略低于 B 类型原材料（由于相差小于 1%，本文暂且忽略），进而认为三者的本征采购单价相等。为了便于研究，本文先对原材料做了等价代换：将其供应量以原材料的商品生产能力表示，采购单价也以本征采购单价表示。为了最大化经济效益，帮助生产企业做出决策，本文建立了供应量可预测的原材料订购、库存方案优化模型。

1.1 问题一

题目中要求对附件一中 402 家供应商进行量化分析，并建立供应商选择的评价指导体系，确定 44 家最重要的供应商。供应商的重要程度受多种因素影响，通过查阅相关文献，利用定量分析的方法，我们选取出适当的指标并根据熵值赋予权重，建立基于熵权逼近理想解方法的供应商排序模型，最后对供应商进行排序优选。

1.2 问题二

题目中要求在问题一结果的基础上，选出能满足企业生产需求的最少供应商，针对这些供应商分别制定最经济的订购方案和损耗最小的转运方案。我们首先利用 0-1 规划选出必要的供应商，同时为了保证原材料供应量充足，我们运用 LSTM 模型预测出转运商的供应水平，并建立了原材料订购方案的线性规划模型。通过对供应过程的计算机仿真，分析订购和转运模型的实施效果。

1.3 问题三

题目中要求在尽量多地采购 A 类和尽量少地采购 C 类原材料的前提下，制定最经济的原材料订购方案和损耗最小的转运方案，并分析方案的实施效果。我们发现，对原材料种类的限制，能通过对问题二模型进行扩展，以作用于目标函数的形式体现在优化模型当中，即将单目标规划转化为多目标规划问题。模型求解后，仍经过计算机仿真，分析模型的优化效果。

1.4 问题四

题目中要求在供应商和转运商有限的情况下，评估企业每周产能的上限。本题取消生产企业每周产能上限的同时，也消除了原材料的库存问题。本问题也转化为在供应商和转运商有限的情况下，求供应链可向企业输送的最大供给量。而通过分析供货数据我们发现，向企业输送的最大供给量主要取决于转运商的转运能力。因此，我们主要对转运商的转运方案进行优化，并据此给出未来 24 周的订购和转运方案。

最后我们对模型进行了中肯的评价和适当的推广。

二、 供应商的选择

通过分析过去五年内，生产企业向 402 家原材料供货商发起的订单数据，可发现其中一些更受该企业青睐，该企业在相同周期里向这些供应商发出更多订单。与之相反，也有一些供应商参与原材料供应较少。因此，为了制定该企业的最优订货策略，有必要筛选出对原材料供应影响较大的供应商，并减少对供应影响较少供应商的依赖。

与此同时，订货法案还受到供货商数量的影响，过多的供应商需要花费企业更多的成本，而且到货的不稳定因素增多，进而有可能影响企业的生产计划；供应商数量过少，虽然能够降低管理成本和订货成本，但是到货的时间和质量的的风险增大，从风险规避的角度来说，供应商数量应该维持在高水平状态^[3]。

综上所述，筛选出供应影响力较强的供应商，并结合生产需求选择合适数量的供应商，与之建立长期、稳定的合作供给关系，能够显著降低该企业的管理成本和资金链风

险。因此，本文通过量化分析供货特征和提出假设，建立并求解相应评价模型，为生产企业订购决策提供基础和指导。

2.1 指标的选取

为了对供应商的供货特征进行量化分析，建立合理的评价模型，本文首先选取了以下的指标：

1. 订货次数 N_j :

订货次数表示供应商过去 5 年向生产企业供货的次数，直接反映出该企业对其的依赖程度。订货次数 N_j 越大，表示企业对该供应商越认可。

$$\nu_{ij} = \begin{cases} 0, & \text{供应商 } S_j \text{ 在第 } i \text{ 周没有订单,} \\ 1, & \text{供应商 } S_j \text{ 在第 } i \text{ 周接到订单;} \end{cases} \quad (1)$$

上式中， ν_{ij} 是表示某供应商在该周是否接到订单的逻辑变量。通过累加求和，得到定货次数

$$N_j = \sum_{i=001}^{240} \nu_{ij}. \quad (2)$$

2. 供应商 $S_j(j = 001, 002, \dots, 402)$ 近五年企业的订货总量 \varkappa_j

企业会向重要的供货商订购大量货物。 \varkappa_j 大的供应商更受企业欢迎，对企业的重要性强。对于供应商 S_j ，有

$$\varkappa_j = \sum_{i=001}^{240} \chi_{ij}, \quad (3)$$

其中， χ_{ij} 是第 i 周，供货商 S_j 接到的订货量。

3. 供应商 $S_j(j = 001, 002, \dots, 402)$ 近五年企业的供货总量 Ψ_j

供应商的供货量能反映供货量的供应能力，供应能力强的供货商能有力地保障企业生产，所以 Ψ_j 越大，相应的供货商越重要，与 \varkappa_j 类似

$$\Psi_j = \sum_{i=001}^{240} \psi_{ij}, \quad (4)$$

其中， ψ_{ij} 是第 i 周，供货商 S_j 对企业的供货量。

4. 平均供货偏差 ε_j :

对企业来讲，越能按照订货量进行供货的供应商是越优质的。我们选择供货量和订货量的差占订货量的比值，表征供货偏差，即供应商 S_j 在第 i 周的供货偏差为

$$\varepsilon_{ij} = \frac{\chi_{ij} - \psi_{ij}}{\chi_{ij}}, \quad (5)$$

而平均供货偏差 ε_j 应为 ε_{ij} 的绝对值的平均值, 即

$$\varepsilon_j = \frac{\sum_{i=001}^{240} |\varepsilon_{ij}|}{N_j}. \quad (6)$$

进而本文得到了供应商在供货时绝对偏差量的期望值

$$E_j = \chi_{ij} \times \varepsilon_j. \quad (7)$$

5. 单次最大供应量 Ψ'_j :

如果供应商能一次性向企业提供大量原材料, 其就能在一定程度上向企业证明其的供应能力强大, 更适合成为对于企业重要的供应商。即单次最大供应量 Ψ'_j 越大, 相对的供应商越重要

$$\Psi'_j = \max\{\psi_{1j}, \psi_{2j}, \dots, \psi_{240j}\}. \quad (8)$$

2.2 基于熵权的 TOPSIS 方法选优

根据过去五年的交易数据, 本文建立了基于熵权法的理想解法供应商评价体系, 并根据评价得分选出供应影响力较强的供应商。

理想解法亦称 TOPSIS 法, 是一种有效的多指标评价方法。理想解法通过构造评价问题的正、负理想解, 根据每个供应商到理想供应商的相对贴近度, 即控制靠近正理想解或远离负理想解的程度, 来对方案进行排序, 以选出最优方案。

TOPSIS 法对样本数据无特殊要求, 并且能清晰地反映各方案的差距, 被广泛应用于多方案多目标的决策评价^[4], 但使用 TOPSIS 法之前必须确定各评价指标的权重系数。

在传统评价模型的应用过程中, 由于指标权重难以确定, 使用场景有很大的局限性。而常见的多要素问题中指标权重的确定方法有: 专家评测法、层次分析法、二向系数法、熵值法、环比分析法、模糊聚类分析法等。由于前三种方法存在着较大的主观因素, 而最后一种方法主要用于模糊指标的重要程度分类, 为提高综合评价的准确性和客观性, 本文故采用熵权法来解决供应商评价选优模型中的权重赋值问题^[5]。

熵权法是一种客观赋权方法。在具体使用过程中, 熵权法根据各指标的变异程度, 利用信息熵计算出各指标的熵权, 从而得出较为客观的指标权重。

2.2.1 权重计算

1. 构造原始数据矩阵

$\mathbf{A} = (a_{jk})_{402 \times 5}$ (用 a_{jk} 指代各供应商的评价值), 将以上五个指标放入以下矩

阵。

$$\begin{pmatrix} W_1 & W_2 & \dots & W_{402} \\ \varkappa_1 & \varkappa_2 & \dots & \varkappa_{402} \\ \Psi_1 & \Psi_2 & \dots & \Psi_{402} \\ \varepsilon_1 & \varepsilon_2 & \dots & \varepsilon_{402} \\ N_1 & N_2 & \dots & N_{402} \end{pmatrix} \quad (9)$$

2. 规范化属性值

得到数据矩阵 $\mathbf{B} = (b_{jk})_{402 \times 5}$ ，为了使每个属性变换后的最优值为 1，且最差值为 0，这里先进行 0—1 标准化

$$b'_{jk} = \frac{b_{jk} - b_{\min}}{b_{\max} - b_{\min}}. \quad (10)$$

此外，为了减小矩阵中的订货量和供货量波动过大的影响，对其进行对数化处理。重新赋值，得

$$b''_{jk} = \ln b'_{jk} (k = 1, 2, 3, 4, 5). \quad (11)$$

3. 利用数据矩阵

计算 $p_{jk} (k = 1, 2, 3, 4, 5)$ ，即第 j 家供应商关于第 k 个指标值的比重

$$p_{jk} = \frac{b''_{jk}}{\sum_{j=1}^{402} b''_{jk}}. \quad (12)$$

4. 计算第 k 项指标的熵值

熵本源于热力学与统计物理，后由香农引入信息论。根据熵的定义，有

$$e_k = -\frac{1}{\ln 402} \sum_{j=1}^{402} p_{jk} \ln p_{jk}. \quad (13)$$

5. 计算第 k 指标的变异系数

$$g_k = 1 - e_k, \quad (14)$$

对于第 k 项指标， e_k 越大，指标值的变异程度就越小。

6. 计算第 k 指标的权重

$$\omega_k = \frac{g_k}{\sum_{k=1}^5 g_k}. \quad (15)$$

2.2.2 供应商评价

1. 用向量规划化的方法求得规范决策矩阵

$$\bar{\mathbf{B}} = (\check{b}_{jk})_{402 \times 5}, \quad (16)$$

其中

$$\check{b}_{jk} = \frac{b''_{jk}}{\sqrt{\sum_{j=1}^{402} b''_{jk}^2}}. \quad (17)$$

2. 构造加权规范阵 $\bar{\mathbf{B}} = (\check{b}_{jk})_{402 \times 5}$

凭借熵权法给定的各属性的权重，得权重向量 $\square = (\omega_1, \omega_2, \omega_3, \omega_4, \omega_5)$ ，则有

$$\check{b}_{jk} = \omega_k \check{b}_{jk}. \quad (18)$$

3. 确定正、负理想解 $\mathbf{C}^+ = (c_1^+, c_2^+, c_3^+, c_4^+, c_5^+)$ 、 $\mathbf{C}^- = (c_1^-, c_2^-, c_3^-, c_4^-, c_5^-)$

正理想解

$$c_k^+ = \begin{cases} \max_j \check{b}_{jk}, & k \text{ 为效益型属性,} \\ \min_j \check{b}_{jk}, & k \text{ 为成本型属性;} \end{cases} \quad (19)$$

负理想解反之。

4. 计算各供应商与正、负理想解的距离

与正理想解的距离

$$s_j^+ = \sqrt{\sum_{k=1}^5 (\check{b}_{jk} - c_k^+)^2}, \quad (20)$$

与负理想解的距离同理。

5. 计算各供应商对理想解的相对接近程度作排序指标值（即综合评价指数）

$$f_j = \frac{s_j^-}{s_j^- + s_j^+}. \quad (21)$$

6. 按 f_j 由大到小排列供应商的优劣次序

2.3 供应商的评价结果

2.3.1 各个指标的权重

运用熵权法，对过去交易数据进行分析，得到各个特征指标的权重，如图 1 所示。




图 1 各指标权重

Fig. 1 Weights of each indicator

2.3.2 供应商综合评价指数

根据评价指标和上文计算出的权重，对供应商进行评价，表 1 是各供应商的综合评价得分。

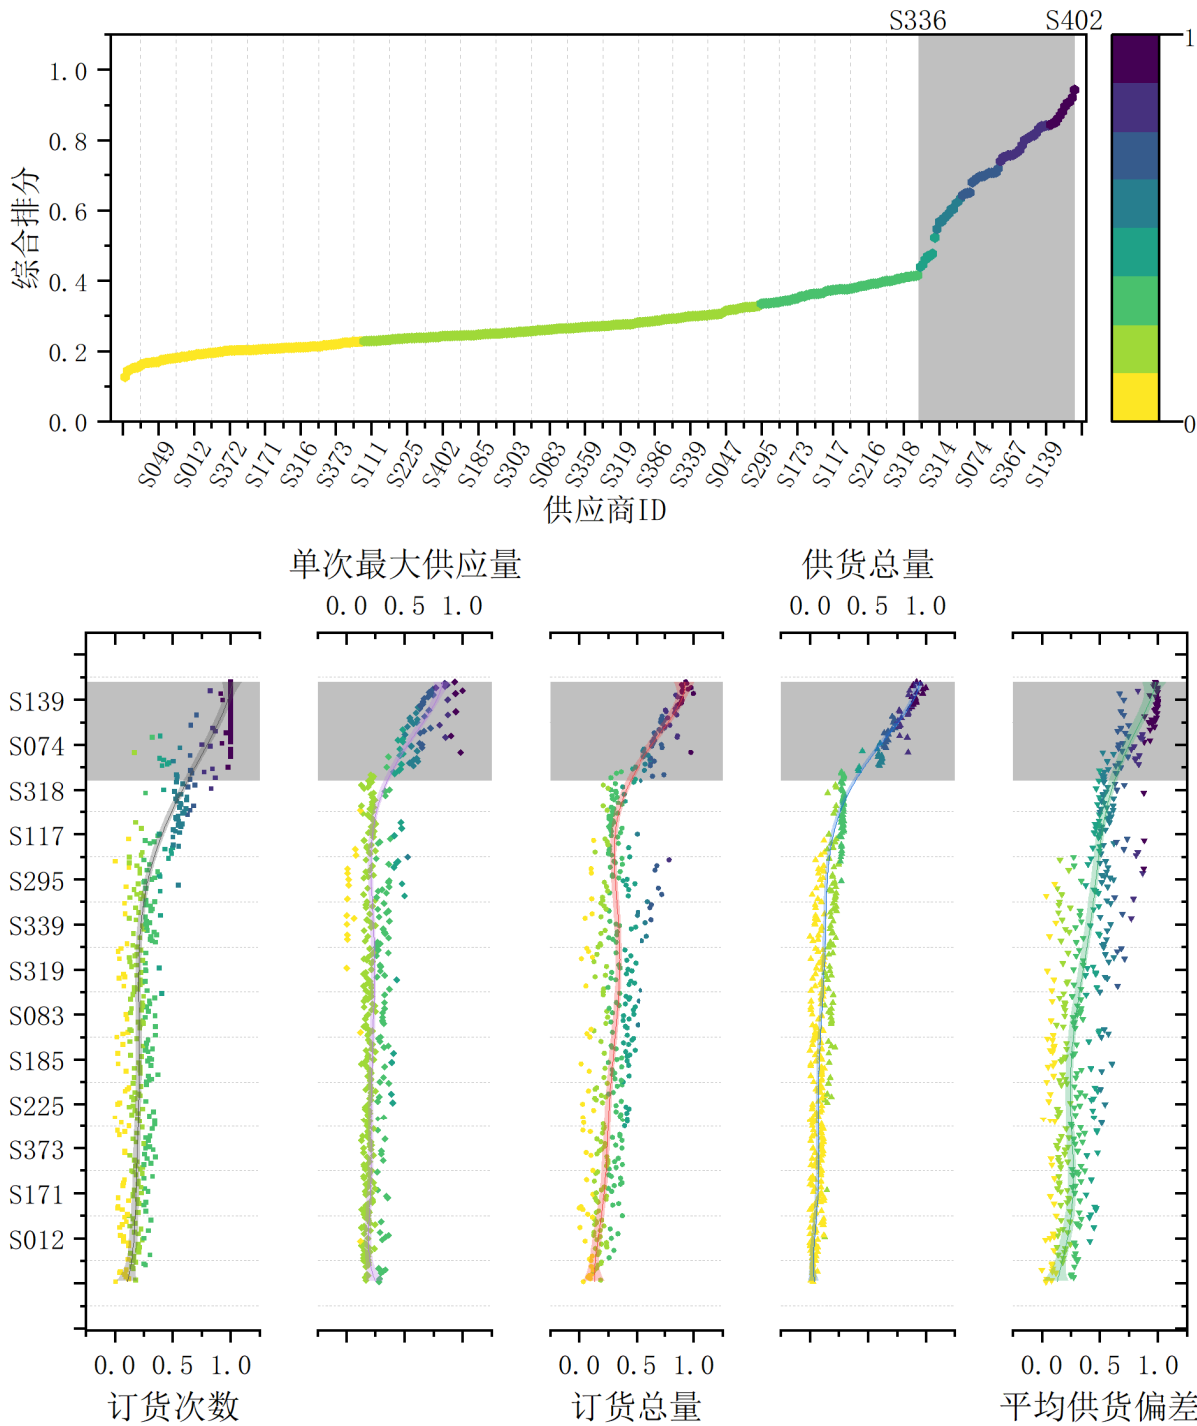


图 1 各指标权重

Fig. 1 Weights of each indicator

表 1 排名前十八名的供应商评价分数

Table 1 Weights of each indicator

供应商	订货次数	订货总量	供货总量	平均供货偏差	单次最大供应量
0	91	350	74.24242424	0.837362637	9.090909091
1	95	515	455	0.490977444	111.6666667
2	199	19831.94444	18247.22222	0.206018934	537.5
3	103	1080.30303	96.96969697	0.794073047	12.12121212
4	114	10896.66667	11520	0.171227722	213.3333333
5	55	641.6666667	41.66666667	0.871212121	6.944444444
6	240	11193.33333	11580	0.379053947	258.3333333
7	56	130.5555556	56.94444444	0.776785714	18.05555556
8	80	1083.333333	46.96969697	0.81125	6.060606061
9	88	872.7272727	257.5757576	0.746306818	45.45454545
10	43	116.6666667	118.0555556	0.494601329	15.27777778
11	68	513.3333333	48.33333333	0.907352941	10
12	29	61.11111111	61.11111111	0.562931034	12.5
13	27	53.33333333	46.66666667	0.574074074	5
14	54	46471.66667	46.66666667	0.808641975	6.666666667
15	22	63.33333333	61.66666667	0.315909091	11.66666667
16	67	323.3333333	230	0.710465529	41.66666667
17	72	171.2121212	100	0.740625	10.60606061

2.3.3 供应商的预选

根据以上评价模型对于各供应商的得分，将供应商由高到低排序，并分别以各供应商及其评价分数为、横坐标，绘制图像。由图 2 可见，供应商的得分状况呈积聚分布，并且在 0.416 分处，有显著的拐点。因此，本文先根据评价分数，首先筛选出 66 家高分供应商。

2.4 供应商数量优化

通过预选供应商，本文已筛选出供应能力较突出的供应商。为了进一步得到合适数量的供应商，满足企业每周生产需求，并使供货最稳定，本文建立供应商选择 0-1 规划模型，以决定实际供货商选取：

$$\begin{aligned}
 \min \quad & \Lambda = \sum_{j=1}^{66} \lambda_j \varepsilon_j \\
 \text{s.t.} \quad & \sum_{j=1}^{66} \lambda_j \bar{y}_j > 2.84 \times 10^4
 \end{aligned} \tag{22}$$

其中， λ_j 是表示第 j 家供应商是否被选上的 0-1 变量，而 \bar{y}_j 表示第 j 家供应商的供货能力，计算方法见于后文。通过对模型的求解，得到最终选定的 44 家供应商。

三、预测未来供货量

3.1 基于神经网络的供货能力预测

为了优化订购方案，首先需要确定可能的供应量，因此对筛选后的供货商的供应量进行预测，再据此制定相应的订货方案。供应商接受订单后，会在自身供货能力范围内，调整供货量以满足订单需要。当订货量过大时，供应商会仅提供其最大供应量，因此往年供应数据可以反映出供应商的供货能力上限，本文依据供应商历史供应情况来预测其未来供应情况。

订货商的供应量受多种不可控因素影响，若仅根据时间变量构建时间序列预测模型，难以准确拟合供应量曲线，预测效果差。若将其做主要影响因素的回归分析，由于影响因素众多且相互耦合，无法综合分析，与此同时，预测过程中也有预测函数难以构建的问题^[6]。

对于复杂的长时间序列预测的问题，相比于传统时间序列预测手段，深度学习方法有着更好的拟合与预测能力。深度学习模型是一种拥有多个非线性映射层级的深度神经网络模型，能够对输入信号逐层抽象并提取特征，挖掘出更深层次的潜在规律^[7]。其中，LSTM 模型弥补了循环神经网络的梯度消失和梯度爆炸、长期记忆能力不足等问题，使得循环神经网络能够真正有效地利用长距离的时序信息^[8]。

因此，本文使用 LSTM 分别对选中的 44 家公司的供货量进行预测。本文在过去五年的交易数据中，以前四年训练神经网络，取第五年为测试集。

LSTM 是由一系列节点（又称 LSTM 单元）组成的。如图??? 所示，LSTM 单元内部主要有三个阶段。在第 t 个节点中：

(1) 忘记阶段——对上一个节点的输入进行选择性的忘记，即遗忘门

$$f^t = \sigma \left(\omega^f \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (23)$$

该阶段通过 Sigmoid 函数，计算得到的 f^t 是一个向量，且每个分量均属于 $[0, 1]$ 。一般分量的值会极其接近 0 或 1，为后续选择 c^{t-1} 中用于计算 c^t 的特征做准备。

(2) 记忆阶段——选择有效的输入值，即输入门

$$i^t = \sigma \left(\omega^i \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (24)$$

该阶段工作原理与忘记阶段类似，将用于对输入的 x^t 进行选择。

(3) 选择阶段——选择输出并放缩，即输出门

$$o^t = \sigma \left(\omega^o \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (25)$$

本阶段得到的 o^t 会放缩 c^t ，进而决定节点的输出

LSTM 的优势是前一节点的状态将随数据一起传入后一节点，但并不向外输出，具体来说也有三个：

(1) 单元状态更新值

$$\check{c}^t = \sigma \left(\omega^c \begin{matrix} x^t \\ h^{t-1} \end{matrix} \right). \quad (26)$$

事实上，单元状态更新值与遗忘门、输入门和输出门的作用类似，而且并不传入后一节点。

(2) 单元状态

$$c^t = f^t c^{t-1} + i^t \check{c}^t. \quad (27)$$

(3) 隐藏状态

$$h^t = o^t \tanh(c^t). \quad (28)$$

最终节点的输出 y^t 也是由 h^t 变化而成的，本文使用的是

$$y^t = \sigma(\omega' h^t), \quad (29)$$

在后文中，使用 ψ_{ij} 以表示，即通过预测得到的第 i 周第 j 家供应商的供应量。

本文的 LSTM 是由 PyTorch 实现的，结构如图??? 所示：




图 2 LSTM 网络结构图

Fig. 2 LSTM network structure diagram

Algorithm 1 Long short-term memory for out model.

Input: 从原始数据中获取原始的订购与供应数据; 从原始数据中挑取前一步筛选的 44 家供应商信息;

Output: 第 i 周第 j 家供应商的预测值 ψ_{ij} ;

- 1: 对数据的 A、B、C 分类, 做均一化预处理;
 - 2: 将数据按供应商拆分为一维时间序列数据;
 - 3: 将一维时间序列数据先按时间窗口切分为二维数据, 以同样的方法, 再将每个时间窗口中的数据切分为特征向量;
 - 4: 对升维后的数据做一次正态标准化缩放, 保存缩放参数;
 - 5: 将处理后的数据送入 LSTM 网络, 训练完毕后, 返回神经网络;
 - 6: 每次预测 1 周, 将预测的得到的 1 周数据重新送入神经网络, 迭代指定此时以得到相应的预测步数;
 - 7: 使用保存的缩放数据, 将预测数据复原。
 - 8: **return** ψ_{ij} .
-




图 2 LSTM 网络结构图

Fig. 2 LSTM network structure diagram

通过分析往年交易数据, 供应商总是根据企业订货量来供应原材料。由于没有考虑提高订购量对供应量的影响, 仅根据往年交易数据进行预测, 模型对供应商实际供应的预测值会偏小。通过对预测结果的检验, 预测中筛选得到的供应商的总供应量确实小于预期。

3.2 供应量修正

为了提高预测的准确性, 本文为模型添加了反映订货量影响的修正。数据显示, 一定范围内, 供应商的供应量会随订货量的增加而增多。而当订货量超出其的供应能力后, 供应商的供货量限于生产条件达到其最大值, 即最大供应量。

进而定义该家供货商的修正比 α_j :

$$\alpha_j = \frac{\beta_j - \gamma_j}{\gamma_j}, \quad (30)$$

在第 j 家供应商的历史数据中，当供货量超过订货量时供货量的平均值记为 B_n ，而 c_n 为当供货量小于订货量时供货量的平均值。

修正后第 j 家供应商在第 i 周的实际供货能力 $\hat{\psi}_{ij} = \alpha_j y_j^i$ 。

3.3 预测模型检验

本文基于企业前四年的供应数据，建立如上原材料供应量预测模型，并将模型预测结果与真实数据比较以检验模型预测准确性，如下图所示：




图2 拟合验证图

Fig.2 Comparison

拟合效果较好，故采取该预测模型以预测供应商供货量。

四、制定订购、库存方案

4.1 基于订货量的供货量确定

在生产厂家选择确定的供应商并发出订单后，供应商在其供货能力范围内将尽可能按照订货量进行供货，实际供货量受其自身供货能力的影响；为了模拟现实中供货量的波动情况，本文令实际供货量偏差符合该供货商过去的供货偏差情况。

预测的供货量为：

$$u_{ij} = \begin{cases} E_j v_{ij}, & v_{ij} \leq \psi_{ij}, \\ E_j \psi_{ij}, & v_{ij} \geq \psi_{ij}; \end{cases} \quad (31)$$

当订货量高于供应商的能力时，供货量不再随订货量增长，可令此时订货量等于供应能力。在此基础上，本文在后文中通过约束 $v_{ij} \leq \psi_{ij}$ ，解决了分段函数线性化的问题。

4.2 制定订购方案

为获得最高收益，在制定订购方案时，需要平衡原料库存量。在供应充足时适当扩大库存，以填补未来原材料不足造成的缺口，使其生产活动稳定进行。为了在尽可能保证产量的前提下，使存储成本最小，本文建立了如下线性规划模型以确定每周的订货量。

分析预测结果，虽然平均每周的供货总量充足（大于 $2.84 \times 10^4 m^3$ ），但仍有部分周供应不足，记缺货量为 $D_i = 2.84 \times 10^6 - u_i$ （供货量充足时， $D_i = 0$ ）。为了在供应不足时也能尽可能地发挥产能，该企业会在供货总量充足的时候中增加进货，即额外订购量 $d_i = u_i - 2.84 \times 10^6$ （供货总量低于 $2.84 \times 10^4 m^3$ 时， $d_i = 0$ ）。

为了保证订购的原材料均被加工为产品，要求 $\sum_{i=1}^{24} D_i \geq \sum_{i=1}^{24} d_i$ 。

令目标函数为企业利润，使企业收益最大，构建线性规划模型：

$$\begin{aligned} \max \quad & p_1 \eta - p_2 \mu_i \\ \text{s.t.} \quad & \sum_{i=1}^{24} D_i \geq \sum_{i=1}^{24} d_i \end{aligned} \quad (32)$$

其中， η 为 24 周内的总产量， $\eta = 24 \times 2.84 \times 10^6 - \sum_{i=1}^{24} D_i + \sum_{i=1}^{24} d_i$ ；第 t 周的原材料库存量 $\mu_t = 2.84 - \sum_{i=1}^t D_i + \sum_{i=1}^t d_i$ 。 p_1 为单位产品的售价，则 $p_1 \eta$ 为企业 24 周的生产所得； p_2 为单位产品所需原料的平均运输和储存成本。该模型中的 p_1 和 p_2 是关键参数：当 p_1 较大时，企业会倾向多投入存储费用来保证产能不被浪费，以生产更多产品赚取高额利润；当 p_2 较大时，企业则会牺牲产量来避免支付昂贵的仓储费用。本文在测试时，产品的售价约比仓储成本高一个数量级。需要泛用时， p_1 和 p_2 应根据实际情况灵活取值。

以上模型的决策变量是订购量 v_{ij} ，得到的最优解代表着每周最经济的订货量。此处由于三种类型原材料的本征采购单价相等，因此在进行运筹时并没有在目标函数中计算。另外，通过对结果的检验，本文发现最优解得订购方案在转运商的能力范围之内，因此忽略了转运商的能力对订货量的限制。

经过以上的优化，本文已经确定了每周的订货总量，需根据各供货商供货能力分配订单。本文依据 2.2 中的各供应商选优顺序，向筛选后的供应商依次订货，直到预计供货量达到预期。

4.3 制定转运方案

为了保证生产的经济效应，企业不仅需要制定订货方案，计划转运商的运输方案也是必要的，本文希望根据上文制定的订货方案进一步计划损耗最少的转运方案。在实际转运过程中，原材料会有一定的损耗，损耗量占供货量的百分比称为“损耗率”。通常情

况下，一家供应商每周供应的原材料尽量由一家转运商运输。为体现供应商 S_j 选择的转运商 T_l ，引入 0—1 变量假设同一家转运商 T_l 的损耗率总是恒定的 u_l ，则有：

$$\begin{aligned} \max \quad & L_i = \sum_{l=1}^8 (u_l \sum_{j=1}^{44} \rho_{ijl} \psi_{ij} p_3) \\ \text{s.t.} \quad & \sum_{l=1}^8 \rho_{ijl} = 1 \end{aligned} \quad (33)$$

式中 p_3 是原材料的采购单价，根据供应商贩卖的原材料类型确定。目标函数 L_i 是第 i 周的损失价值，故希望最小。该 0—1 规划模型每周运筹一次，制定该周的转运方案。约束条件表示一家供应商每周供应的原材料只由一家转运商运输，且每家转运商的运输原料的能力为 6000 立方米/周。事实上，根据预测模型，发现有的供应商单周供应量大于 6000 立方米，此时便无法只由一家转运商运输了。但这种情况发生次数较少，通过手工分配后，转运效果整体良好。

五、模型检验

最后，本文根据前四年的交易数据，基于以上方法制定了优化后的订购方案，对第五年企业生产情况进行模拟，与现实情况比较以检验模型实施效果。




图3 final test

Fig.3 finaltest

六、原材料的订购和转运方案扩展

本题要求在尽量多地采购 A 类和尽量少地采购 C 类原材料的前提下，制定最经济的原材料订购方案和损耗最小的转运方案，并分析方案的实施效果。

6.1 制定订购方案

该企产成本，要减少转运及仓储的成本。三类原材料运输和业为了压缩生存储的单位费用相同，但 A 类原材料的商品生产能力比 C 类原材料强，因此企业会尽量多地采购 A 类和尽量少地采购 C 类原材料。本文忽略了原材料类型偏好对每周订货总量的影响，而主要关注于供应商订购量分配的变化。因此，问题 2 中的每周订货总量计划保持不变。

问题 2 中，原材料的订购数量是直接根据供应商的评价来进行分配的。问题 1 中建立的评价模型并未重点关注供应商贩卖的原材料类型，本文通过依据供应商贩卖的原材料类型，对供应商的评价加分，以尽量多地采购 A 类和尽量少地采购 C 类原材料。考虑到综合评价指标均小于 1 分，本文对售卖 A 类原材料的供应商加 1 分，令企业尽量多地采购 A 类原材料。联系上文，B 类原材料的本征采购单价实际上略高，因此，本文没有对 C 类原材料的供应商扣分。

6.2 制定运输方案

因为 A 类原材料的采购单价较高，因此对转运损耗更加敏感。问题 3 中企业计划尽量多地采购 A 类原材料，所以迫切需要制定合理的运输方案，以确保转运商的转运损耗率尽量少，来达到压缩生产成本的目的。问题 2 中侧重于经济效益，要求损耗最少，而问题 3 要求转运损耗率尽量少，因此对问题 2 中的 0-1 规划模型稍加改动：

式中 L'_i 代表第 i 周的转运损耗量，由于希望转运损耗率尽量少，故此处转运损耗量应取最小值。

参考文献

- [1] 杨庆军, 孙满. 浅谈 ERP 环境下的原材料管理[J]. 中国外资, 2012(7): 196-196.
- [2] 李红燕. 论企业原材料的管理和研究[J]. 财会学习, 2018(2): 181-181.
- [3] 顾丽娟. 基于最优供应商数量的补货策略研究[J]. 洛阳理工学院学报: 社会科学版, 2014(6): 21-24.
- [4] 金王莉. 基于熵权 TOPSIS 法的产业综合优势分析——以苏州制造业为例[J]. 中国商论, 2018(28): 159-162.
- [5] 马丽娟. 基于供应链管理的供应商选择问题初探[J]. 工业工程与管理, 2002(06): 23-25.
- [6] 李鹏, 何帅, 韩鹏飞, 等. 基于长短期记忆的实时电价条件下智能电网短期负荷预测[J]. 电网技术, 2018, 42(12): 4045-4052.

- [7] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [8] 王鑫, 吴际, 刘超, 等. 基于 LSTM 循环神经网络的故障时间序列预测[J]., 2018.